

随机建模课程学习大纲

模块 1: Fourier-Based Option Pricing (基于傅里叶的期权定价)

学习目标

- 理解为什么在期权定价中引入傅里叶变换方法，并掌握其优势（如广泛适用性、精确度和计算速度等）¹。
- 熟悉傅里叶变换和快速傅里叶变换 (FFT) 的基本概念，为后续定价方法打下基础。
- 掌握**特征函数**的定义及其在期权定价中的关键作用，学会通过特征函数解决复杂模型中无法直接获得概率密度的问题²³。
- 学习两种经典的傅里叶期权定价思路：Lewis (2001) 提出的基于特征函数的定价公式，以及 Carr-Madan (1999) 提出的基于FFT的快速定价方法⁴。
- 将上述方法应用于黑-舒模型 (Black-Scholes)，验证傅里叶定价得到的结果与闭式解一致，并比较不同方法的计算效率。为更复杂的模型（如 Heston 随机波动率模型）使用傅里叶技术作准备。

内容结构与核心概念

1. 引入傅里叶定价方法的动机：传统衍生品定价在简单模型（如 Black-Scholes）下可以求出闭式解，但对更复杂的模型（如 Heston 随机波动率模型）往往无法得到解析解⁵。傅里叶方法通过利用**特征函数**（即资产终值分布的傅里叶变换）提供了一种通用、高效且精确的数值定价手段¹。直观来说，特征函数完全刻画了随机变量的分布，可以替代概率密度出现在定价公式中，避免直接处理复杂密度函数的困难⁶。傅里叶定价的优势包括：**通用性**（适用于只要能写出特征函数的绝大多数模型），**精度**（通过数值积分可达任意精度）以及**速度**（相较蒙特卡洛模拟等方法显著提速）⁷。

2. 傅里叶变换与特征函数：课程首先回顾傅里叶变换的定义和反演公式，以及 Parseval 恒等式等基础数学工具⁸⁹。傅里叶变换将实域上的函数（如概率密度）映射到频域，对于期权定价问题，可利用这一变换将资产终值分布的信息浓缩在特征函数中⁶。**特征函数** $\phi_X(u)$ 定义为随机变量 X 的富氏变换，即 $\phi_X(u) = E[e^{i u X}]$ ¹⁰。特征函数与分布一一对应，可以通过傅里叶反演恢复原始密度。因此，只要模型能写出资产终值 S_T 的特征函数，就能够利用傅里叶方法定价欧式期权⁶。这一思想的物理图像是：与其在价格空间困难地求概率密度，不如转到频率空间利用特征函数“易于处理”的特性。

3. Fourier 定价公式 (Lewis 方法)：Lewis (2001) 提出了利用特征函数定价欧式看涨期权的半解析公式¹¹。其关键在于将期权最终收益 payoff 的傅里叶变换与资产价格终值分布的特征函数相结合，通过傅里叶反演得到现值。对于到期 payoff $C_T = \max(e^{s} - K, 0)$ （这里 $s = \ln S$ ），Lewis 方法给出了期权现值的表达式¹²¹³：

$$C_0 = e^{-rT} \frac{1}{2\pi} \int_{-\infty + i u_i}^{+\infty + i u_i} \Phi(u) du,$$

其中 $\Phi(u)$ 包含了 payoff 的傅里叶变换和资产价格特征函数的乘积。特别地，选取适当的积分路径（如虚部 $u_i = 0.5$ ），可将积分化为实数轴上的积分形式。经过推导，可以得到一个实数积分公式用于数值计算：

$$C_0 = S_0 - \sqrt{S_0 K} e^{-rT} \frac{1}{\pi} \int_0^\infty \frac{\Re\{e^{izk} \phi_{ST}(z - i/2)\}}{z^2 + 1/4} dz,$$

其中 ϕ_{ST} 表示对数资产价格 S_T 的特征函数, $k = \ln(S_0/K)$ ¹⁴。上述公式是 Lewis 方法的核心结果, 它将欧式看涨期权价格表示为关于资产特征函数的一个积分。当模型的特征函数已知时, 只需进行一次积分即可得到价格。

4. Carr-Madan 方法与 FFT: 另一种思路由 Carr 和 Madan (1999) 提出。他们通过对支付函数进行适当平滑与截断, 引入辅助的损失函数, 并应用快速傅里叶变换 (FFT) 将积分定价过程加速。直观而言, FFT 可以高效地计算一系列离散点的傅里叶积分, 从而同时求出一系列行权价对应的期权价格。Carr-Madan 方法通过选择合适的阻尼因子 α 将看涨期权支付的傅里叶变换 $\Psi(v)$ 表达出来, 并利用 FFT 快速得到价格在不同行权下的值 ¹⁵ ¹⁶。该方法极大降低了计算复杂度, 实现了 $O(N \log N)$ 的定价算法, 非常适合计算完整隐含波动率曲面。

5. 在 Black-Scholes 框架下应用与验证: 课程在本模块结尾, 将傅里叶方法应用于 Black-Scholes 模型作为检验。Black-Scholes 模型下欧式看涨期权的闭解已知 (BS 公式)。另一方面, 我们可以推导 Black-Scholes 的特征函数并代入上述 Fourier 定价公式。Black-Scholes 模型下对数价格的特征函数为 ¹⁷:

$$\phi_{BS}(u, T) = \exp\left((r - \frac{1}{2}\sigma^2)iuT - \frac{1}{2}\sigma^2u^2T\right) \text{【16†L55 – L63】},$$

将其代入 Lewis 公式进行数值积分, 可计算得到欧式看涨期权价。课程笔记展示了用 `scipy.integrate.quad` 进行数值积分, 并与 Black-Scholes 解析解对比, 验证结果完全一致 ¹⁸ ¹⁹。此外, Carr-Madan FFT 方法也被用于计算相同的期权价格, 得到相同结果 ²⁰。通过对比三种方法的运行时间, 发现直接套用 BS 公式最快, 而傅里叶积分方法和 FFT 方法略慢但也在毫秒级别 ²¹。这体现了: 在简单模型下傅里叶方法能重现正确结果, 在复杂模型下则能提供其他方法难以获得的解。

重要公式

- **傅里叶变换与反演:** 若 $f(x)$ 为可积函数, 其傅里叶变换定义为

$$\mathcal{F}\{f(x)\}(u) = \int_{-\infty}^{+\infty} e^{iux} f(x) dx,$$

傅里叶反演公式为

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-iux} \mathcal{F}\{f(x)\}(u) du,$$

其中 i 是虚数单位 ²² ⁹。在期权定价中, payoff 函数和密度函数的傅里叶变换常用于推导定价公式。

- **特征函数定义:** 随机变量 X 的特征函数 $\phi_X(u)$ 定义为 $\phi_X(u) = E[e^{i u X}]$ ¹⁰。特征函数等同于概率密度的傅里叶变换, 完全决定了分布。例如, Black-Scholes 模型下对数价格 $s_T = \ln S_T$ 的特征函数为

$$\phi_{BS}(u, T) = \exp\left(iu[s_0 + (r - \frac{1}{2}\sigma^2)T] - \frac{1}{2}\sigma^2u^2T\right) \text{【16†L55 – L63】}.$$

- **Lewis (2001) Fourier 定价公式:** 对于欧式看涨期权, Lewis 给出的半解析公式为 ¹⁴:

$$C_0 = S_0 - \sqrt{S_0 K} e^{-rT} \frac{1}{\pi} \int_0^{\infty} \frac{\Re\{e^{iz \ln(S_0/K)} \phi_{ST}(z - \frac{i}{2})\}}{z^2 + \frac{1}{4}} dz,$$

其中 ϕ_{ST} 表示底层资产终值对数价的特征函数。该公式将定价问题转化为对特征函数的积分，是傅里叶定价法的核心结果 ¹⁴。

- **Carr-Madan (1999) FFT 定价公式：** Carr-Madan 方法通过引入阻尼因子 α ，将看涨期权价 $C(K)$ 与其傅里叶变换 $\psi(\nu)$ 联系起来 ¹⁶：

$$\psi(\nu) = \int_0^\infty e^{i\nu k} e^{-\alpha k} C(e^k) dk,$$

然后利用 FFT 以离散形式高效计算 $C(K)$ 。其具体实现涉及选取适当的 α 保证积分收敛，并对 $\psi(\nu)$ 进行插值和反变换，最终批量得到价格。 ²³ ²⁴。

编程实现提示

本模块配套的 Jupyter Notebook 提供了详实的编程示范，帮助理解傅里叶方法的实际操作。首先，笔记中使用 Python 库计算 Black-Scholes 公式的闭式解作为基准 ²⁵ ²⁶。随后，Notebook 展示了如何编写 **特征函数** `BS_characteristic_func(u, x0, T, r, sigma)` 来计算 Black-Scholes 模型的特征函数 ²⁷ ²⁸。接着，实现了计算 Lewis 公式中积分内 integrand 的函数，例如 `BS_integral(u, S0, K, T, r, sigma)` 根据传入的 u 值返回 integrand 的实部 ¹⁹ ²⁹。利用 SciPy 库的积分函数 `quad`，对 0 到 $+\infty$ 区间进行数值积分，并封装为 `BS_call_Lewis` 函数计算期权价格 ³⁰ ³¹。同理，笔记实现了 FFT 定价：通过设置合适的离散步长和频率范围，使用 NumPy 的 `fft` 函数高效求解期权价格序列 ³² ³³。值得注意的是，实现 FFT 时需要对特征函数进行修正以确保收敛，例如在实部增加衰减因子 α 并构造修改后的特征函数 (`modcharFunc`) 来计算 FFT 输入 ³⁴ ³⁵。

完成三种方法的实现后，Notebook 将 **欧式看涨期权价格** 分别用解析解、Lewis 积分、FFT 方法计算并打印比较 ³⁶ ³⁷。结果显示三种方法计算的价格完全一致，证明傅里叶方法的正确性 ³⁷。最后，Notebook 还比较了不同方法的执行时间：可以让程序多次运行 `BS_analytic_call`（闭式解）、`BS_call_Lewis`（傅里叶积分）和 `BS_call_FFT`（FFT）并打印耗时 ²¹ ³⁸。实验结果表明，对于 Black-Scholes 模型，闭式解最快，但傅里叶积分和 FFT 方法也非常迅速，仅在微秒/毫秒级别。这一编程练习加深了对傅里叶定价效率的直观认识。

课程练习与回顾建议

- **比较计算效率：** 课后建议读者亲自调整和运行 Notebook，比较三种方法在不同参数（如积分上限、FFT 网格密度）下的计算时间。例如，可以增加 FFT 点数或积分精度，观察计算耗时如何变化，从而体会 FFT 在大规模定价中的速度优势。
- **理解特征函数影响：** 尝试在代码中修改资产价格过程的特征函数（例如将 Black-Scholes 的常数波动率修改为不同值，或引入简单跳跃项），然后使用傅里叶积分公式计算期权价格。通过与 Black-Scholes 基准价格对比，观察特征函数变化如何影响期权定价，并思考其金融意义（如跳跃风险溢价）。
- **拓展阅读：** 参考 Hilpisch (2015) 《Python 衍生品分析》第 6 章 ³⁹ 获取关于傅里叶定价的更多背景知识。课程还鼓励阅读 Lewis (2001) 原论文以深入了解傅里叶定价公式的推导 ⁴⁰。这些练习和阅读有助于巩固对本模块傅里叶定价方法的理解。

模块 2: Bates (1996) 模型 – 结合 Heston(1993) 随机波动率和 Merton(1976) 跳跃扩散

学习目标

- 理解将**随机波动率**模型与**跳跃扩散**模型相结合的必要性：体会市场数据中同时存在波动率微笑/偏斜和资产价格尾部厚度等现象，各单一模型难以全面捕捉，因此需要综合模型来解释 41 42。
- 熟悉 **Bates (1996) 模型** 的基本构成和风险中性动态：掌握其风险中性SDE，包括带跳跃项的股票价格过程和均值回复的方差过程，并了解跳跃风险漂移修正 $r_{J</sub></sub></sub>$ 的含义 43 44。
- 推导 Bates 模型的**特征函数**：学习如何将 Heston (1993) 随机波动率模型和 Merton (1976) 跳跃模型各自的特征函数结合，得到联合过程的特征函数 45 46。理解特征函数乘积的背后假设（两个过程相互独立）以及这种方法的普适性。
- 运用傅里叶变换方法定价 Bates 模型下的欧式期权：能将模块1中的 Fourier 定价公式应用于 Bates 模型，替换相应的特征函数，计算欧式看涨期权价格半解析解 47 48。
- 掌握 Bates 模型参数的**校准**方法：通过课程示范，了解如何利用市场期权价格反推模型参数（如初始方差 v_0 、均值回复速度 κ 、长程方差 θ 、跳跃强度 λ 、跳跃幅度均值 $\mu_{J</sub></sub></sub>$ 等） 49 50。理解校准的优化目标（例如最小化模型价与市场价的误差）和实现手段（如全局搜索 brute force 初值+局部搜索 fmin）以及注意事项。

内容结构与核心概念

1. 随机波动率与跳跃扩散的结合动机：在此前课程中，我们已学习了多种期权定价模型，涵盖厚尾分布（如跳跃扩散模型）和波动率微笑（如 Heston 随机波动率模型）等特征 41。Bates (1996) 模型试图将**Heston (1993)**的随机波动率和**Merton (1976)**的跳跃扩散两种机制合二为一，以同时捕捉市场期权价格中观察到的**偏峰、厚尾**现象和**隐含波动率曲面**形状 51 42。简单来说，Heston 模型能解释波动率随状态变化（波动率微笑），Merton 跳跃模型能解释资产价格突然跳变（厚尾分布），组合后的 Bates 模型有望更贴近真实市场行为。其风险中性假设下股票价格 S_t 服从带随机方差和跳跃的过程，而方差本身服从均值回复扩散，从而将两类特征综合起来。

2. Bates 模型的动态结构：课程详细列出了 Bates 模型的风险中性动态方程 43 52：

- 股票价格过程:** $dS_t = (r_t - r_J)S_t dt + \sqrt{\nu_t} S_t dW_t^{(1)} + J_t S_t dN_t$,
其中 N_t 为强度 λ 的 Poisson 跳跃过程，跳跃幅度 J_t 使 $\ln(1 + J_t) \sim N(\mu_J, \delta^2)$ 。 $r_J = \lambda(e^{\mu_J + \delta^2/2} - 1)$ 是跳跃导致的漂移修正项，确保资产价格在风险中性下的漂移为无风险利率 r 44 53。直观来说，每发生一次跳跃，资产价格乘以 $(1+J)$ ， r_J 起到扣除跳跃对漂移的影响，使模型无套利。
- 方差过程:** $d\nu_t = \kappa_\nu(\theta_\nu - \nu_t)dt + \sigma_\nu \sqrt{\nu_t} dW_t^{(2)}$,
其中 ν_t 表示瞬时方差， κ_ν 为均值回复速率， θ_ν 为长期均值， σ_ν 为方差的波动率参数，两个 Wiener 过程 $W^{(1)}, W^{(2)}$ 的相关系数为 ρ 54 55。这一过程与 Heston 模型中的方差过程一致，意味着波动率随机变化且均值回复。

Bates 模型将上述两个过程结合，假设跳跃与连续扩散部分相互独立 45。相应的**特征函数**也能拆解成两部分独立贡献，这为傅里叶定价提供了便利。

3. Bates 模型的特征函数推导：由于跳跃扩散与波动率过程独立，Bates 模型的特征函数可表示为两者特征函数的乘积 46 56：

$$\phi_{Bates}(u, T) = \phi_{Heston}(u, T) \times \phi_{Merton_jump}(u, T).$$

课程中首先回顾了 Merton (1976) 模型的特征函数形式：⁵⁷ 对于纯跳跃扩散模型（带对数正态跳跃，且跳跃与扩散部分拆分开），其特征函数为

$$\phi_{Merton}(u, T) = \exp\left(iu\omega T - \frac{1}{2}\sigma^2 u^2 T + \lambda T(e^{iu\mu_J - \frac{1}{2}u^2\delta^2} - 1)\right),$$

其中 $\omega = r - \frac{1}{2}\sigma^2 - \lambda(e^{\mu_J + \delta^2/2} - 1)$ （确保漂移为 r ）⁵⁸ ⁵⁹。接着引入 Heston 模型的特征函数（在模块 1 已推导）：

$$\phi_{Heston}(u, T) = \exp\{H_1(u, T) + H_2(u, T)\nu_0\},$$

其中 H_1, H_2 为给定参数下的确定性函数⁶⁰ ⁶¹（较长，此处不展开，详见 Heston 1993 原文）。Heston 特征函数体现了方差的随机性，例如含有 ρ （相关系数）和复数参数 u 的复杂表达⁶² ⁶³。通过简单相乘，得到 Bates 模型完整特征函数 $\phi_{B96}(u)$ 。这一结果非常简洁且重要：两个独立部分的特征函数相乘，极大方便了后续定价⁴⁶。模型所需的仅仅是能够写出各子过程的特征函数——这也是傅里叶方法通用性的体现。

4. Fourier 定价在 Bates 模型中的应用：有了 $\phi_{B96}(u)$ ，我们即可将其代入模块 1 介绍的 Fourier 定价公式中。课程中说明，由于 Bates 模型没有解析解，傅里叶积分是获取价格的有效途径⁴⁷。具体做法是在数值积分函数中，用 Bates 的特征函数替换 Black-Scholes 的特征函数，即对 Lewis 公式中的 integrand 做相应修改。在课程 Notebook 的实现中，定义了 Bates 模型的**积分内核函数** `B96_int_func(u, ...)`，计算 integrand 实部⁶⁴ ⁶⁵。随后使用 SciPy 数值积分得到价格。这种半解析计算相比直接模拟路径，速度和精度都更有保证。最后，课程也讨论了 Carr-Madan FFT 可用于 Bates 模型，但需要对跳跃项进行适当阻尼处理（因为跳跃引入的高频波动可能影响 FFT 收敛），原理与模块 1 类似，不再详述。

5. Bates 模型的参数校准：本模块强调了**校准**在复杂模型应用中的重要性。由于 Bates 模型有较多参数（包括波动率部分的 $\kappa, \theta, \sigma, \rho, \nu_0$ ，和跳跃部分的 λ, μ_{J}, δ ），需要利用市场期权数据进行校准。课程采用了分步校准的策略：首先**校准纯随机波动率部分或纯跳跃部分**，然后结合起来微调。具体而言，Lesson 1 先使用 Merton (1976) 跳跃模型拟合市场价格，获取初步的跳跃参数估计⁶⁶ ⁶⁷；Lesson 2 介绍 Bates 模型理论⁴⁹，Lesson 3/4 则演示**同时考虑随机波动率和跳跃的校准过程**⁵⁰。校准通过最小化模型价格与市场价格误差实现。需要注意的是，校准常是一个高维非线性优化问题：课程建议先使用粗略网格或暴力搜索（brute force）在宽范围找到近似最优解，再用诸如 Nelder-Mead（`scipy.optimize.fmin`）这样的局部优化细化结果⁶⁷ ⁶⁸。校准过程中还涉及筛选期权数据，例如只使用接近平值的期权以减少偏差⁶⁹ ⁷⁰。实验表明，Bates 模型通常能比单纯的 Heston 或 Merton 模型更好地拟合市场隐含波动率曲面。然而，也存在**识别困难**：不同参数组合可能产生类似的价格曲面，需要结合金融意义和稳健性进行选择。课程最后指出，在校准时可选择直接拟合隐含波动率而非期权价格，以减少价格分布尾部的不均衡影响⁷¹ ⁷²。

重要公式

- **Bates 模型风险中性动态**⁴³ ⁴⁴：

$$dS_t = (r - r_J)S_t dt + \sqrt{\nu_t} S_t dW_t^{(1)} + J_t S_t dN_t,$$

$$d\nu_t = \kappa_\nu(\theta_\nu - \nu_t)dt + \sigma_\nu \sqrt{\nu_t} dW_t^{(2)},$$

其中 $r_J = \lambda(e^{\mu_J + \delta^2/2} - 1)$ 是跳跃部分的漂移修正⁷³。两个 Wiener 过程相关系数为 ρ ，Poisson 过程 N_t 强度为 λ ，跳跃幅度 $J_t = e^{Y_t} - 1$ 且 $Y_t \sim N(\mu_J, \delta^2)$ 。

- **Bates 模型特征函数**⁴⁶：由于股票收益的连续部分与跳跃部分独立，特征函数可分解为二者乘积：

$$\phi_{Bates}(u, T) = \phi_{Heston}(u, T) \phi_{Merton}(u, T),$$

其中 ϕ_{Heston} 是Heston随机波动率模型的特征函数， ϕ_{Merton} 是纯跳跃扩散模型的特征函数⁴⁶。后者进一步可拆为**扩散部分**和**跳跃部分**的乘积（扩散部分与Black-Scholes类似，跳跃部分贡献 $\exp[\lambda(e^{iu\mu_J - 0.5u^2\delta^2} - 1)T]$ ）^{45 74}。

- **Lewis定价公式在Bates模型下的实现**：形式上与模块1的公式一致，只需将特征函数替换为 $\phi_{\text{Bates}}(u)$ ：

$$C_0^{\text{Bates}} = e^{-rT} \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-iuk} \frac{\phi_{\text{Bates}}(u - i/2)}{u^2 + 1/4} du,$$

其中 $k = \ln(S_0/K)$ 。实际计算时取从0到 ∞ 的实数积分形式并取实部¹⁴。Carr-Madan方法同样适用，只是需要对跳跃项引入阻尼因子 α 以确保 Fourier 变换收敛。

- **Merton 模型特征函数**⁵⁷（校准跳跃初值时用到）：

$$\phi_{\text{Merton}}(u, T) = \exp\left(iu\left(r - \frac{1}{2}\sigma^2 - \lambda(e^{\mu_J + 0.5\delta^2} - 1)\right)T - \frac{1}{2}\sigma^2 u^2 T + \lambda T(e^{iu\mu_J - 0.5u^2\delta^2} - 1)\right).$$

该式由跳跃扩散过程解析推导而来，便于同市场数据拟合以估计 λ, μ_J, δ 等参数。

编程实现提示

课程的第二模块提供了分步骤构建 Bates 模型的代码范例。首先，在 Module 2 Lesson 1 的Notebook中，实现并验证了**Merton (1976) 跳跃扩散模型**的定价与校准，这是Bates模型的一部分。在代码中定义了 Merton 模型的特征函数 `M76_char_func(u, T, r, sigma, lamb, mu, delta)`^{75 76}，然后与Lewis公式类似，定义积分内核函数 `M76_integration_function(u, ...)` 并通过数值积分求出欧式看涨期权价格 `M76_call_value`^{77 78}。通过调用 `M76_call_value`，Notebook 演示了给定参数下 Merton 模型计算的期权价格^{79 80}。接下来，进行**Merton模型的参数校准**：读取上一模块提供的欧洲期权市场数据（Euro Stoxx 50指数期权），筛选接近平值的看涨看跌期权^{67 69}。利用 SciPy 的优化函数（如 `brute` 网格搜索和 `fmin` 局部优化），最小化模型价格与市场价格平方误差，求解最优跳跃强度 λ 及跳跃分布参数 μ, δ ^{81 68}。优化过程中Notebook将误差函数打印、绘图，帮助理解收敛过程和参数敏感性。Lesson 1 最终输出了校准得到的一组 Merton 模型参数，用以近似刻画跳跃行为。

在 Lesson 2 理论讲解后，Lesson 3/4 的Notebook 则聚焦**Bates 模型的定价与校准**。首先实现了 Bates 模型的特征函数与定价函数。如代码片段所示，定义 `H93_char_func` 计算 Heston 部分特征函数、`M76J_char_func` 计算（调整后的）纯跳跃特征函数，再将二者相乘得到 `B96_char_func`^{82 56}。随后定义 `B96_int_func(u, ...)` 作为 Lewis 公式的积分 integrand^{83 64}。通过这些函数，很容易编写 `B96_call_value` 来计算 Bates 模型的期权价格。Notebook 接着重复类似的**校准步骤**：由于参数更多，采用**分段优化策略**。代码先固定一部分参数，优化另一部分，例如可以先用Lesson1得到的跳跃参数，优化Heston部分参数，再反过来。最后综合前几步结果作为初值，进行全参数的联合优化^{84 71}。在校准过程中，Notebook会输出每轮迭代的参数值和误差，帮助分析优化走势。此外，代码绘制了校准后模型价格与市场价格在各执行价下的对比图^{85 86}，显示出 Bates 模型对市场期权价格的拟合程度相当理想⁸⁵。课程强调，可以尝试不同初值、多次运行校准以确保找到全局最优，也可以调整目标（如改为拟合隐含波动率）。通过这些编程练习，学生能够掌握如何将理论模型应用于真实数据，并理解模型参数对市场的影响。

课程练习与回顾建议

- **模块内练习：**在Notebook校准完成后，课程建议尝试**同时校准多个到期日**的期权。例如，将三个不同到期的期权数据同时纳入误差函数，观察模型能否兼顾各期限隐含波动率曲面⁸⁴⁷¹。这个练习可以加深对模型能力和局限的认识：Bates模型在同一组参数下难以完美拟合所有期限的期权，这是模型假设与市场复杂性之间的差异。
- **改变参数检验敏感性：**学生可以选取校准所得参数，利用 `B96_call_value` 计算不同执行价/到期下的期权价格，然后**微调某个参数**（如增大跳跃强度 λ 或改变相关系数 ρ ），再次计算价格曲线。比较两组价格曲面的差异，以定性理解各参数的作用：例如 λ 增大会提高远价外期权价格（肥尾效应更强）， ρ 影响短期隐含波动率偏斜等。
- **理论推导练习：**尝试根据课程给出的 Heston 和 Merton 模型特征函数，推导课程中直接给出的 Bates 特征函数公式⁴⁶。这个过程需要用到概率论中**独立随机变量特征函数相乘**的性质，是对模块内容的良好巩固。推导完成后，可将结果与课程提供的公式比对，确认正确性并深化理解。
- **进一步阅读：**参考 Bates (1996) 原论文《Jumps and Stochastic Volatility...》了解模型在外汇期权上的应用⁸⁷。阅读 Hilpisch (2015) 第9章可获取 Python 实现此类模型的更多示例⁴⁹。这些扩展阅读将有助于将所学模型置于更广阔的金融工程背景中考量。

模块 3：Bakshi-Cao-Chen (BCC, 1997) 模型 – 引入随机利率的三因子模型

学习目标

- 回顾并掌握**短期利率模型**的基本原理和应用：熟悉 Vasicek (1977) 模型与 Cox-Ingersoll-Ross (CIR, 1985) 模型的形式与差异，理解均值回复过程的统计特征以及在利率衍生品定价中的作用⁸⁸⁸⁹。
- 比较 Vasicek 与 CIR 模型对利率路径的影响：通过模拟不同参数下的利率路径，直观体会 CIR 模型保证非负利率且波动随水平变化（volatility-of-volatility效应），而 Vasicek 模型方差恒定且可能出现负利率⁹⁰⁹¹。理解这些模型特性的物理含义（如利率在高位时波动幅度更大等）。
- 学习**短期利率模型的校准方法**：掌握如何利用市场利率数据（如零息收益率曲线或远期利率）估计模型参数。特别地，掌握用**最小二乘法**拟合 CIR 模型的瞬时前向利率曲线的方法⁹²⁹³。
- 理解**Bakshi-Cao-Chen (1997) 模型**构建思路：在已有随机波动率+跳跃模型基础上，引入随机利率因子形成三因子模型。掌握 BCC 模型的风险中性动态方程，理解其假设（如资产与利率无相关）和每个子模型的作用⁹⁴⁹⁵。
- 掌握 **BCC 模型的分步校准流程**：学习如何先分别校准利率模型与资产价格模型，再将结果结合进行联合校准的策略⁹⁶⁹²。了解分步校准的好处（降低维度、提高稳定性）以及在综合校准时可能遇到的问题（例如参数耦合、计算负担增加等）。通过实际案例掌握如何逐步完成 BCC 模型对市场期权和利率数据的拟合。

内容结构与核心概念

1. **短期利率模型简介：**课程从利率衍生品定价的角度介绍**短期利率模型**，特别是 Vasicek 和 CIR 两种经典模型⁸⁸。Vasicek 模型假设短期利率 r_t 服从均值回复的 Ornstein-Uhlenbeck 过程：

$$dr_t = \kappa_r(\theta_r - r_t)dt + \sigma_r dW_t,$$

其解析解已在衍生品课程中推导过（收益率正态分布，可能为负）⁸⁹。CIR 模型则在 Vasicek 基础上引入了 $\sqrt{r_t}$ 项：

$$dr_t = \kappa_r(\theta_r - r_t)dt + \sigma_r \sqrt{r_t} dW_t,$$

CIR 保证了利率的非负性，因为当 r 很小时扩散项趋近0^{97 98}。课程通过模拟对比展示了两模型的差异：如采用相近参数同时模拟100条一年内利率路径，发现 Vasicek 路径波动范围更广，而 CIR 路径收敛于均值附近且波动程度随水平降低^{99 91}。这印证了模型性质：CIR 在低利率时波动率降低，使利率不易偏离均值太远^{91 100}。**物理图像**是：当利率极低时，CIR模型的随机扰动几乎消失，因此利率很难进一步跌破0；而Vasicek模型无此限制。对于金融市场，这意味着CIR模型更适合描述正利率环境下的利率演化。

2. CIR 模型的市场校准：为了应用短期利率模型，需要根据当前收益率曲线确定参数。课程重点介绍了**利用即时远期利率曲线校准 CIR**的方法⁹²。首先，从市场获取不同期限的零息利率或即时远期利率数据（课程示例使用九个期限的欧元区无风险利率，包括1天、7天...一年等期距的年化利率）¹⁰¹。将这些利率转换为**连续复利零息率**以便计算¹⁰²。然后，将 CIR 模型在理论上给出的远期利率公式与市场远期利率进行拟合：CIR模型下 t 时刻的瞬时远期利率 $f(0,t)$ 有解析表达（依赖 $\kappa_r, \theta_r, \sigma_r$ ）^{93 103}。通过最小化理论远期曲线与市场远期曲线的均方误差，可以得到最佳参数估计。课程提供的笔记采用了SciPy的优化工具进行这一拟合，并给出了得到的参数值^{104 105}。例如，校准结果 $\kappa_r \approx 0.0683$, $\theta_r \approx 0.2077$, $\sigma_r \approx 0.1126$ 表示利率均值回复很慢、长期均值20.77%、波动适中¹⁰⁵。校准完成后，将这些参数用于后续 BCC 模型中利率部分的定价。课程强调，在校准 CIR 时要确保费勒条件 $2\kappa\theta \geq \sigma^2$ 以避免零利率被触及的概率为1情况¹⁰⁶——优化中可加入此约束避免无效参数。

3. BCC (1997) 模型概述：Bakshi-Cao-Chen 模型将**随机利率**纳入了资产定价模型，形成同时包含**随机波动率、跳跃扩散和随机利率**三要素的综合模型^{94 107}。其动机在于：前两个模块模型只考虑了股票价格自身的不确定性，但在长期期权定价或宏观环境下，利率变化也是重要风险来源。BCC 模型通过令短期无风险利率 $r_{t < \tau < /sub>t < /sub>$ 遵循 CIR 过程，并假设利率过程与资产价格过程独立无关，从而扩展了 Bates 模型^{108 109}。具体来说，BCC 模型可描述为：

- 股票价格 $S_{t < /sub>t < /sub>$ 遵循 **Bates 模型**（随机波动+跳跃）的扩展，但漂移项改为 $r_{t < /sub>t < /sub>$ 随时间变动：⁹⁵

$$dS_t = (r_t - r_J)S_t dt + \sqrt{v_t}S_t dW_t^{(1)} + J_t S_t dN_t,$$

其中 $r_{t < /sub>t < /sub>$ 非常数而是由利率模型给出，其他项与模块2相同。

- 波动率过程 $v_{t < /sub>t < /sub>$ 仍为 Heston 1993 模型的方差过程¹¹⁰，与模块2一致。

- 短期利率 $r_{t < /sub>t < /sub>$ 遵循 **CIR 模型**：¹¹¹

$$dr_t = \kappa_r(\theta_r - r_t)dt + \sigma_r\sqrt{r_t}dW_t^{(3)},$$

并假设 $W^{(3)}$ 与资产价格的两个 Wiener 过程独立（相关系数为0）¹¹¹。这一假设意味着股票市场风险与利率风险在模型中未直接相关，有利于简化特征函数推导和定价。

在物理上，BCC 模型刻画这样一个情景：市场存在波动率随机波动、价格偶有跳跃的股票，同时宏观利率环境也在随机变化且独立影响贴现因素。由于相关性假设简单，**BCC 模型的特征函数**可以通过将 Bates 模型特征函数与利率过程特征函数相乘得到（类似模块2方法）；课程中虽未详细推导，但明确指出由于利率独立，可将贴现因子部分拆开处理。总的来说，BCC 模型将前述各子模型模块化组合，是对现实市场更全面的抽象。

4. BCC 模型的定价与校准：因为 BCC 模型综合了三个随机过程，其定价一般没有解析解，只能采用数值方法。课程选择继续使用傅里叶变换方法：在给定利率特征函数和资产特征函数的前提下，可写出包含三部分的特征函数，并代入 Fourier 定价公式得到价格。不过，在实际计算时，由于 $r_{t < /sub>t < /sub>$ 不再是常数贴现率，Fourier定价公式需做调整：欧式期权现值为 $C_0 = E[e^{-\int_0^T r_t dt} \text{payoff}]$ 。在独立假设下，贴现因子 $P(t) = e^{-\int_0^t r_s ds}$ 的特征函数可解析得到，然后与资产端特征函数合并。实现层面较复杂，但课程强调因为独立性，此合并是可行的¹¹²。实际计算中，更直接的方式是**蒙特卡洛模拟**：课程在笔记中提到，已分别实现模拟 Vasicek/CIR 和 Bates 模型的代码，因此完全可以通过模拟同时生成许多路径 ($S_{t < /sub>t < /sub>}, r_{t < /sub>t < /sub>}$) 来计算期权价格。然而，蒙特卡洛精度和效率不如傅里叶法，因此未在课堂上细节展开。

在参数校准方面，课程采用**分步校准**降低难度⁹⁶。具体4个步骤为^{113 114}：(1) **校准利率模型**：利用收益率曲线得到 $\kappa_{_r}$, $\theta_{_r}$, $\sigma_{_r}$ （已在前述步骤完成）；(2) **校准资产的随机波动率部分**：暂不考虑跳跃，使用 Heston 模型拟合期权隐含波动率曲面的一部分，得到初步的 $\kappa_{_v}$, $\theta_{_v}$, $\sigma_{_v}$, ρ , $v_{₀} > 0$ ；(3) **校准跳跃部分**：在引入跳跃后，利用此前 Heston 拟合的基础，只调整 λ , $\mu_{_J}$, δ 去进一步拟合价格尾部；(4) **综合校准**：将以上参数作为初始值，同时优化所有参数使模型对各期限各执行价期权价格的误差整体最小^{84 71}。课程特别指出，由于(4)非常复杂，可将(1)-(3)结果作为最终参数，无需完全追求步骤(4)的全局最优，因为那可能导致过拟合且经济含义不明。这体现了金融建模中的**实用权衡**：分步得到的参数组往往已足够解释主要现象，而且更符合各部分的经济预期。校准完成后，课程通过绘图比较模型与市场的价格/隐含波动率，再次验证 BCC 模型虽然复杂但能够较好地拟合真实数据。最后，课程讨论了一些更深入的问题，例如**选择哪些期权数据用于校准**：一次校准太多不同到期的合约可能降低拟合精度^{84 71}，实际应用中通常会根据定价需求选择性校准对应期限。此外，还提及了有时直接对隐含波动率而非价格进行校准的好处，在于均衡不同执行价处的权重，这可以在后续课程中深入探讨⁷²。

重要公式

- **Vasicek (1977) 短期利率模型**⁸⁹：

$$dr_t = \kappa_r(\theta_r - r_t)dt + \sigma_r dW_t,$$

其中 κ_r 是均值回复系数， θ_r 是长期均值， σ_r 是利率波动率。Vasicek 模型解的期望趋近 θ_r ，方差呈指数衰减，解为正态分布。缺点是 r_t 可为负值。

- **CIR (1985) 短期利率模型**⁹⁷：

$$dr_t = \kappa_r(\theta_r - r_t)dt + \sigma_r \sqrt{r_t} dW_t,$$

相比 Vasicek，多了 $\sqrt{r_t}$ 项，使得当 $r_t \rightarrow 0$ 时波动项消失，保障 $r_t \geq 0$ 。CIR 模型要求 $2\kappa_r\theta_r \geq \sigma_r^2$ （费勒条件）以避免过程撞零。CIR 模型下零息债券价格和远期利率有闭式解，可用于参数估计^{93 103}。

- **BCC (1997) 模型动态**^{95 111}：由 Bates 模型与 CIR 利率模型组成：

$$\begin{cases} dS_t = (r_t - r_J)S_t dt + \sqrt{\nu_t} S_t dW_t^{(1)} + J_t S_t dN_t, \\ d\nu_t = \kappa_\nu(\theta_\nu - \nu_t)dt + \sigma_\nu \sqrt{\nu_t} dW_t^{(2)}, \\ dr_t = \kappa_r(\theta_r - r_t)dt + \sigma_r \sqrt{r_t} dW_t^{(3)}, \end{cases}$$

其中 $W^{(3)}$ 与 $W^{(1)}, W^{(2)}$ 无相关， r_J 同模块2定义，三过程独立。^{95 111}

- **CIR 模型校准的误差函数**（基于即时远期率）⁹³：

$$\text{MSE}(\kappa_r, \theta_r, \sigma_r) = \frac{1}{N} \sum_{i=1}^N \left(f^{\text{mkt}}(T_i) - f^{\text{CIR}}(T_i; \kappa_r, \theta_r, \sigma_r) \right)^2,$$

其中 $f^{\text{mkt}}(T_i)$ 是市场第 i 个期限的瞬时远期利率， $f^{\text{CIR}}(T_i)$ 是 CIR 公式给出的远期利率（可由零息利率封闭解求出）。通过最小化 MSE 可得到最佳参数。^{115 116}

- **BCC 模型校准步骤提示**：⁹⁶ 课程建议的四步校准在概念上等价于分块优化问题，可记为：

- $\min_{\kappa_r, \theta_r, \sigma_r} \text{MSE}_{\text{rates}}$
- $\min_{\kappa_\nu, \theta_\nu, \sigma_\nu, \rho, v_0} \text{MSE}_{\text{options}}^{(\text{Heston})}$ （固定 $\lambda=0$ ）
- $\min_{\lambda, \mu_J, \delta} \text{MSE}_{\text{options}}^{(\text{jump})}$ （固定 Heston 参数）

- $\min \text{MSE}_{\text{options}}^{(full)}$ (所有参数)

实际操作时可跳过第4步或以第4步微调前几步结果，以平衡计算成本和精度。 86 117

编程实现提示

模块3的课程笔记提供了从利率模型到综合模型的一系列编程实例。首先在 Lesson 1 Notebook 中，实现并比较了 Vasicek 与 CIR 两种模型的模拟。代码分别定义了函数 `vasicek(r0, k, theta, sigma, T, N, M)` 和 `cir(r0, k, theta, sigma, T, N, M)` 来模拟 M 条长度为 N 的利率路径 118 119。以给定初始利率 r0、年化波动率 sigma 等参数，利用欧拉法递推生成路径，并将 Vasicek 与 CIR 结果分别绘制。120 121 绘图部分将100条模拟路径叠加：代码用 Matplotlib 将 Vasicek 路径绘为蓝色、CIR 路径绘为红色，并在同一图中对比 122 122。图形显示出红色CIR路径总体波动略小且没有穿过零的情况，与蓝色Vasicek路径形成对照 122 91。通过这一步，学生可以借助可视化手段加深对模型行为的理解。

接下来，Lesson 2 笔记演示了CIR模型的校准。代码载入预先准备的利率数据，例如 `rate_list` 数组存储各期限市场年利率 101。然后计算相应的瞬时远期利率 `f` 数组 123 102。构造误差函数 `CIR_error_function(alpha)`，其中 alpha 包含 $(\kappa_r, \theta_r, \sigma_r)$ 三个参数，函数内部按给定参数计算CIR模型理论远期率并与市场 forward rates比较均方差 115 116。为防止参数无效，代码中加入了条件判断，如若 $2\kappa_r\theta_r < \sigma_r^2$ 则直接返回一个大误差值以排除不符费勒条件的参数 124。随后使用 `scipy.optimize.fmin` 以初值 `[1.0, 0.02, 0.1]` 开始最小化误差 125。优化完成后，打印出所得参数并存入变量备用 126 105。这个 Notebook 一步步计算并输出迭代信息（包括警告，如超出函数评估次数等 105），帮助理解优化过程。完成利率模型校准后，笔记将参数应用到构造折现因子曲线，证明模型与市场数据的贴合程度。

在 BCC 模型部分，Lesson 3/4 笔记综合使用了前述结果。首先将 Module2 已实现的 Bates 模型定价代码和本模块获取的 CIR 参数结合。在构建 BCC 定价时，笔记提供了分阶段计算的范例：例如，在校准 BCC 前，先用 CIR 参数计算贴现因子曲线，然后在 Bates 定价公式中引入一个贴现因子调整。代码可能定义 `BCC_call_value` 函数，内部调用 Bates 模型的定价函数，但对每个模拟价乘以 $e^{-\int_0^T r_s ds}$ 的期望近似（可通过 Gauss-Laguerre 积分或模拟实现）。虽然课程并未给出所有细节，但提供了校准框架：利用之前模块2校准得到的 Bates 参数作为初值，再加上当前模块得到的利率参数，一并构成 BCC 参数集，然后使用 SciPy 优化最小化期权价格误差 86 71。由于参数较多，可选择固定某些参数不动，只优化主要几个以加速收敛。笔记通过打印每轮误差、参数变化，以及最终拟合曲线与市场的比较图，让学生了解校准效果。特别地，图表展示校准前后隐含波动率曲面的变化、模型曲面与市场数据的偏差 85 86。这些编程实践让学生直观体会 BCC 模型如何通过调节参数来匹配复杂的市场现象，并理解为何分步优化可以取得良好效果。

课程练习与回顾建议

- **模拟验证练习：**建议学生利用已校准的 Vasicek/CIR 参数，模拟未来利率路径并计算相应的债券价格或互换率，观察模型预测分布是否合理。例如，可模拟一年后利率分布，与市场远期利率分布进行比较，检验模型的置信区间覆盖情况。这有助于检验利率模型对市场的拟合度。
- **多期限期权校准：**尝试选取两个不同到期日的期权数据，同时校准 BCC 模型参数（即在误差函数中合并两个到期的价格误差）。比较同时校准与分别校准的结果：同时校准可能导致某些期限拟合变差，但却给出了一套兼顾多期限的参数。这让学生体会模型的局限：一个参数集难以完美符合所有期限曲线，反映出现实中模型简化带来的偏差 84 71。
- **检验无相关假设：**BCC 模型假设利率与资产价格独立。作为练习，学生可以尝试在模拟中引入一些相关性（例如令资产过程和利率过程分享部分随机数），然后重新校准或定价，观察结果变化。这将帮助理解相关性假设对模型简化的重要性，以及如果相关会给定价带来何种复杂影响。
- **深入阅读与拓展：**查阅 BCC 1997 年论文 127 了解原作者对该模型的检验和评价。论文中对比了多种模型在美式 S&P 500 指数期权上的表现，学生可以将课程所学 Bates/BCC 模型与文中结果对照，加深认识。此外，可阅读 Gatheral (2006)《波动率曲面》关于含跳跃的局部波动率模型的章节，看看与 Bates/BCC 的联系和区别。这些拓展有助于将 BCC 模型置于更广泛的模型谱系中理解。

模块 4：马尔可夫链与隐藏马尔可夫模型 (Markov Chains & HMM)

学习目标

- 理解**马尔可夫链**的基本概念：掌握马尔可夫性质（记忆无损性）的含义，即未来状态的分布只依赖当前状态、不依赖过去历史¹²⁸。了解有限状态马尔可夫链的构成要素：状态空间、**转移概率矩阵** P 以及 n 步转移概率的计算方法^{129 130}。
- 能将马尔可夫链应用于金融实例：熟悉信用评级迁移问题中的马尔可夫链模型，理解如何由**评级转移矩阵**预测未来债券价值分布^{131 132}；掌握“赌徒破产问题”中吸收马尔可夫链的思路，计算破产概率等指标；理解如何将连续状态过程（如 AR(1) 时间序列）离散化为马尔可夫链近似，从而简化分析^{133 134}。
- 理解**隐藏马尔可夫模型 (HMM)** 的结构：知道 HMM 由隐藏的马尔可夫链和观测序列组成，包含状态转移概率、观测概率分布以及初始状态分布等要素^{135 136}。理解 HMM 在金融中的典型应用，如用隐藏状态表示市场“牛市/熊市”情景、观测量为资产收益，从而建模**市场状态切换**。
- 掌握**Hamilton 滤波**等 HMM 状态估计方法：理解前向-后向算法的原理，能够写出递推公式：利用前一步的状态概率预测下一步，然后结合新观测更新当前状态的概率¹³⁷。学习**Kim 平滑**的概念，用于估计全样本下各时刻的状态概率^{138 139}。
- 了解**EM 算法**在 HMM 参数估计中的作用：理解期望-最大化(EM)算法通过交替的“给定当前参数计算隐状态概率”（E步）和“给定隐状态概率重新估计参数”（M步）来迭代逼近最优参数^{140 141}。能够解释 EM 算法如何降低直接极大化观测数据对数似然的难度，并应用于两状态模型（如波动率指数 VIX 的高低波动率状态切换模型）参数估计^{142 143}。

内容结构与核心概念

1. 马尔可夫链基础：课程以离散时间、有限状态的马尔可夫链为出发点，介绍了马尔可夫性质和状态转移矩阵的定义¹²⁹。对于任意状态集合 S ，马尔可夫链的一步转移概率 $p_{ij} = P(X_{t+1} = s_j | X_t = s_i)$ 构成矩阵 P ¹⁴⁴。马尔可夫性质意味着历史信息不再影响下一步，只当前状态有用¹²⁸。课程还推导了 **n 步转移概率**的计算：转移矩阵的 n 次幂 P^n 的 (i,j) 元素即为从状态 i 到状态 j 经过 n 步的概率^{145 146}。例如，对于两状态链有简单公式： $P_{ij}^2 = \sum_k p_{ik}p_{kj}$ ¹⁴⁵，在矩阵语言下对应 P^2 的 (i,j) 元。这些数学性质方便求解长期分布（当 $n \rightarrow \infty$ 时 $P^{ⁿ}$ 收敛到稳态分布）。**物理图像上**，马尔可夫链是一种无记忆的状态跳跃过程，长期看会停留在某种平衡状态分布，课程通过例子说明了如何计算这一平衡分布。

2. 金融应用示例：课程通过**信用评级迁移**案例，展示了马尔可夫链在金融风险管理中的应用¹³¹。给定评级类别 (AAA, AA, ..., D) 的转移矩阵 $P^{₀}$ （如标准普尔的历史统计），可以预测债券未来价值的不确定性。例如，课程构造了一个五年期 BB 评级债券的估值问题：假设当前评级为 BB，基于评级一年后的转移概率和不同评级下债券价格/收益率（通过远期利率假设给出），**计算一年后债券价值的期望与分布**^{147 148}。具体步骤包括：(1) 根据远期利率曲线折现一年后各评级的债券和票息价值；(2) 利用转移矩阵计算一年后各评级的概率分布（即 P 矩阵 BB 行对应的概率）；(3) 得到债券一年后价值的**期望和方差**¹⁴⁹。课程通过代码演示了如何归一化评级转移矩阵去除无评级状态，计算一年后各评级概率^{150 151}，进而算出价值分布。这一例子说明马尔可夫链可用于信用风险评估，如计算违约分布、估计信用价值调息等。

另一应用是**赌徒破产问题**，课程将其描述为一个带吸收态的马尔可夫链：赌徒的资金额为状态，0 和目标财富为吸收状态，中间状态按一定胜率 p 向上或 $q=1-p$ 向下转换。课程要求学生构建转移矩阵并计算最终破产概率。实际破产概率公式为 $\frac{(q/p)^i - (q/p)^N}{1 - (q/p)^N}$ （当 $p \neq q$ ）或 i/N （当 $p=q=0.5$ ），但课程更强调**利用马尔可夫链原理推导**。通过这个经典问题，学生理解了如何解带吸收态的马尔可夫链长期行为：求解吸收概率和吸收时间等。

此外，课程还探讨了**连续过程的离散近似**：以 AR(1) 自回归过程为例，将其状态空间离散成多个区间，构造马尔可夫链近似此过程¹³⁴。比如，将标准正态 AR(1) 的值域离散为有限等级，则可用马尔可夫链模拟其演化。这在数量金融中很常见，如用离散网格近似短期利率模型（Quadratic Gaussian 等）以简化计算。

3. 隐藏马尔可夫模型 (HMM): 在掌握显性马尔可夫链后, 课程引入HMM的概念¹³⁵。HMM包含两个层面: 底层是隐藏的马尔可夫链 $\{S_t\}$, 无法直接观测; 另一层是观测序列 $\{Y_t\}$, 其分布依赖于隐藏状态¹³⁶。形式化描述包括: N个隐藏状态、状态转移矩阵 P; 观测可能取 M 种值 (或连续分布), 每个隐藏状态对应一个观测概率分布 $f(y|s=i)$ ^{136 152}; 以及初始状态分布 π 。HMM 的典型问题有: **前向计算(Filtering)**, 即给定模型参数和观测, 计算当前时刻各隐藏状态的概率分布; **后向计算(Smoothing)**, 计算给定全样本观测后各时刻状态的概率; **解码**, 求最可能的状态序列; **学习**, 根据观测数据估计模型参数。课程重点讨论了前两类问题和参数估计问题。

4. Hamilton 滤波与状态估计: Hamilton (1990) 滤波是HMM在计量经济中的常用算法, 用于估计当期隐藏状态概率^{153 137}。其核心递推包括两步: **预测和更新**。预测步利用前一期滤波结果 $\xi_{t|t}(i) = P(S_t = i | Y_{1:t})$ 计算下一期先验 $\xi_{t+1|t}(j) = \sum_i \xi_{t|t}(i) p_{ij}$ ¹⁵⁴。更新步结合观测 $Y_{t+1} = y$ 计算后验:

$$\xi_{t+1|t+1}(j) = \frac{\xi_{t+1|t}(j) f(y_{t+1}|S_{t+1}=j)}{\sum_k \xi_{t+1|t}(k) f(y_{t+1}|S_{t+1}=k)},$$

这样即可得到第 t+1 期各状态的概率¹³⁷。直观上, 预测步根据马尔可夫链转移扩散概率质量, 更新步按似然重新分配权重。课程强调, 这一递推与卡尔曼滤波形式类似, 只是HMM的状态空间离散、观测可能离散或连续。

5. 模型参数估计与 EM 算法: 当 HMM 的转移概率和观测分布未知时, 需要根据观测序列估计。这通常通过极大似然法完成, 但直接对隐藏状态求和会导致似然函数复杂。**EM算法**提供了有效求解手段^{140 143}。课程以两状态正态HMM (例如高低波动率状态下观测值服从不同正态分布) 为例, 介绍了 EM 步骤:

- E步: 假设一组参数 θ , 先用 Hamilton 前向滤波算出每期处于状态 i 的概率 $\xi_{t|T}(i)$ (前向后向结合, 可得到平滑概率, 即考虑全样本信息的状态概率)^{155 138}。再计算“隐含”的对数似然 (完全数据对数似然的期望)^{156 157}。例如, E步会计算各时刻属于状态1或2的加权观测值平均, 作为后续估计均值的依据。
- M步: **给定平滑概率**, 最大化关于 θ 的期望对数似然^{158 159}。对于两状态HMM, 这意味着重新估计两高斯的均值、方差, 以及转移概率 p_{11}, p_{22} 。例如, 新估计的状态 i 均值 $\mu_i = (\text{加权观测之和})/(\text{状态 i 的权重和})$ ^{160 161}。转移概率也可由平滑概率计算:

$$p_{ij}^{(new)} = \frac{\sum_{t=1}^{T-1} P(S_t = i, S_{t+1} = j | Y_{1:T}; \theta^{old})}{\sum_{t=1}^{T-1} P(S_t = i | Y_{1:T}; \theta^{old})},$$

课程材料中通过Kim平滑结果估计这些统计量^{162 163}。

通过 E-M 交替迭代, 模型参数逐步收敛到局部极大似然估计。课程举了**VIX指数双状态模型**的案例: 假设VIX有“高波动”和“低波动”两种隐含状态, 各状态下 VIX日变化服从不同正态分布^{164 165}。应用 EM 算法, 可以估计出高低波动状态的平均水平、波动率, 以及状态转换概率。课程提供的Notebook利用合成数据或真实 VIX 数据进行了模拟估计演示: 先生成一段隐藏状态序列和对应的观测序列, 然后用 EM 过程尝试“还原”原参数^{166 167}。结果表明 EM 能逐步逼近真值, 但也提醒收敛到局部最优的可能。**物理解释:** EM 的 E步相当于猜测隐含市场状态序列, M步基于猜测调整模型, 当模型能更好解释观测后, 反过来更新状态猜测——如此循环直到稳定。在金融应用中, EM广泛用于估计包含隐藏因子的模型, 如混合分布、Markov regime-switching 等。

重要公式

• **马尔可夫性质**¹⁶⁸: 对于马尔可夫链 $\{X_t\}$, 有

$$P(X_{t+1} = j | X_t = i, X_{t-1} = x_{t-1}, \dots, X_0 = x_0) = P(X_{t+1} = j | X_t = i) = p_{ij},$$

当前状态充分决定下一步分布, 历史其余部分可以忽略。

- **n步转移概率公式** ¹⁴⁵ :

$$P(X_{t+n} = s_j | X_t = s_i) = (P^n)_{ij} = \sum_{k_1, \dots, k_{n-1}} p_{ik_1} p_{k_1 k_2} \dots p_{k_{n-1} j},$$

其中 P^n 是转移矩阵的 n 次矩阵乘积 ¹⁴⁵。特别地，两步转移概率矩阵 $P^2 = P \times P$ 。这一公式可递推计算长时期后的状态概率分布。

- **隐藏马尔可夫模型参数** ¹³⁶ : HMM 由 $(P, \{f(y|s=i)\}_{i \in S}, \{\pi_i\}_{i \in S})$ 定义。其中 P 是隐藏状态转移矩阵， $f(y|s)$ 是观测概率（或概率密度）函数集合， π 是初始状态分布。 ¹³⁶

- **Hamilton 滤波递推** ¹³⁷ :

- 预测: $\xi_{t+1|t}(j) = P(S_{t+1} = j | Y_{1:t}) = \sum_{i \in S} \xi_{t|t}(i) p_{ij}$. ¹⁵⁴

- 更新: $\xi_{t+1|t+1}(j) = \frac{\xi_{t+1|t}(j) f(y_{t+1}|S_{t+1}=j)}{\sum_k \xi_{t+1|t}(k) f(y_{t+1}|S_{t+1}=k)}$.

初始时刻采用先验 π 。反复使用上式，可得到每期的隐藏状态分布估计（滤波值）。

- **EM算法 in HMM** ¹⁴³ ¹⁶² : 对观测似然 $L(\theta) = P(Y_{1:T}|\theta)$ 迭代极大化:

- E步: 计算给定当前参数 $\theta^{(old)}$ 下每期的平滑概率 $\xi_{t|T}(i) = P(S_t = i | Y_{1:T}; \theta^{(old)})$ 以及相邻状态联合概率 $\zeta_t(i, j) = P(S_t = i, S_{t+1} = j | Y_{1:T}; \theta^{(old)})$ 。

- M步: 更新参数使对数完全数据似然期望值最大。对两状态HMM:

转移概率更新: $p_{ij}^{(new)} = \frac{\sum_{t=1}^{T-1} \zeta_t(i, j)}{\sum_{t=1}^{T-1} \xi_{t|T}(i)}$. ¹⁶²

观测分布参数更新: 例如正态HMM中，状态 i 的新均值

$$\mu_i^{(new)} = \frac{\sum_{t=1}^T \xi_{t|T}(i) y_t}{\sum_{t=1}^T \xi_{t|T}(i)}.$$

方差类似更新 ¹⁶⁰。重复迭代直至参数收敛。

编程实现提示

模块4的Notebook通过一系列实例来巩固马尔可夫链和HMM的概念。首先，在 Lesson 1 中，笔记实现了基本的马尔可夫链计算：定义状态和转移矩阵，例如用 Python 字典定义评级到索引的映射 **RATINGS** ¹⁶⁹、以 NumPy 矩阵存储评级迁移概率 **P0** ¹⁷⁰。接着，代码对矩阵进行**归一化处理**（如去除不评级列，确保每行和为1）¹⁷¹。通过 NumPy 的矩阵运算，可以方便地计算一年后评级分布 = 当前状态向量 × P 矩阵。例如代码中 **P = (P0.T/np.sum(P0, axis=1)).T** 完成归一化 ¹⁵¹，然后提取BB行得出BB级一年后转AA、AAA等的概率。随后，笔记使用这些概率计算债券在每种评级下的一年后价值，并加权求期望 ¹³¹ ¹³²。绘图或打印可以展示价值的分布情况。这个实现让学生亲眼看到，如何用几行矩阵运算和索引操作，就能模拟债券评级迁移对价值的影响。

关于**赌徒破产问题**，虽然课程可能未提供完整代码，但鼓励学生自行编码：设赌徒初始资金 i 、目标 N ，胜率 p ，用数组 **dp[i]** 表示资金为 i 时破产概率。根据马尔可夫链吸收原理，可列状态方程：**dp[0]=1, dp[N]=0**，其余 **dp[i] = p*dp[i+1] + (1-p)*dp[i-1]**。学生可写一个小循环迭代求解（或解二项递推公式）。这个编程练习加深对马尔可夫链吸收态的理解。

在 Lesson 3 关于**隐藏马尔可夫模型**，Notebook 构造了模拟数据来验证算法：例如生成长度 T 的状态序列和对应观测序列 ¹⁷² ¹⁷³。状态转移概率和观测分布参数可先设定真实值，然后用接下来的算法去估计。Notebook 实现了 HMM 滤波：定义矩阵或数组存储 $\xi_{t|t}(i)$ 并递推 ¹⁷⁴ ¹³⁷。然后实现平滑：先用滤波结果作为末期边界条件，再反向递推平滑概率（这一部分课程可能略过，但实际可实现）。在参数估计方面，Notebook 采用 EM 算法：初始化猜测参数后，不断迭代 E/M 步。E步利用前向滤波、以及一个后向递推得到每期状态概率（代码

可在前向结果基础上结合Bayes公式计算 $\xi_{t|T}(i)$)。M步则根据 E步结果更新参数。例如代码中会计算每个状态下观测值的加权平均作为新均值 160，以及计算新的转移概率（可通过计数平滑概率的转移频率实现）。每次更新后，代码计算对数似然，若提高不明显则停止迭代。

课程中一个引人兴趣的Notebook示例是**VIX指数的隐马尔可夫模型**。若数据量较大，笔记可能读取真实的 VIX 历史数据（比如CSV文件） 175 176。然后对每日变化率应用两状态HMM。代码可能使用上面实现的 EM 过程来估计参数，并输出结果，比如两个隐藏波动率状态下的均值和方差，以及状态转移概率 160 161。此外，代码可能可视化滤波得到的**隐含状态概率时间序列**，叠加在VIX走势图上，用不同颜色区域标示高波动和低波动时段。这可以直观验证模型分辨市场状态的能力，例如看到金融危机等时期被模型识别为高波动状态。这一编程实践将理论应用于真实金融数据，使学生理解HMM在金融时间序列分析中的威力。

课程练习与回顾建议

- **信用风险练习**：基于课程提供的评级转移矩阵，要求学生计算不同起始评级债券在若干年后的违约概率。例如，可以让学生编写程序，计算5年内BB级债券违约（状态D）的概率。这个练习需要对转移矩阵求幂并关注吸收态概率，有助于熟练掌握马尔可夫链的矩阵计算方法。
- **赌徒破产概率验证**：鼓励学生推导赌徒破产概率的解析解，并通过数值模拟验证。在模拟中，让赌徒重复赌数千次试验，统计破产频率，与理论概率比较。通过编程和理论对比，学生可以加深对马尔可夫链吸收性质和期望计算的理解。
- **HMM滤波实践**：选取一段已知机制的序列（如人工生成某两状态切换的序列），应用编程实现Hamilton 滤波算法，计算每期状态概率。然后将结果与真实隐藏状态对比评估准确率。如果准确率不高，可调整观测分布假设或参数，体会模型错设对滤波效果的影响。这一练习可以培养调试HMM模型的技巧。
- **EM算法稳健性探究**：尝试多次用不同初始参数运行EM算法估计同一HMM模型参数，观察结果是否收敛到相同值。如果出现不同收敛结果，思考可能原因（如局部极值）。学生可以据此理解EM算法敏感性，并练习通过多次随机初始化来提高全局最优机会的经验方法。
- **扩展阅读**：建议阅读 Hamilton (1990) 原论文，了解其在经济周期分析中的应用；以及 Cappe 等人所著《HMM实践指南》以深入掌握前向后向算法和EM算法的数学细节。对于有兴趣的学生，可进一步研究马尔可夫链蒙特卡洛（MCMC）方法在Bayesian隐马尔可夫模型估计中的应用，与EM对比其优劣。通过这些拓展，学生可以在更高层次上理解本模块内容。

模块 5：动态规划与强化学习 (Dynamic Programming for RL)

学习目标

- 了解**强化学习**框架下决策问题的形式化描述：掌握**马尔可夫决策过程(MDP)**的基本构成，包括状态集合 S 、动作集合 A 、状态转移概率 $P(s'|s, a)$ 、即时奖励函数 $r(s,a)$ ，以及未来回报折现因子 γ 等 177 178。理解智能体与环境交互的机制：在每一状态选择动作、获得奖励并转移到下一状态，目标是最大化长期累计奖励 179 180。
- 掌握**值函数**的概念和意义：理解**状态值函数** $v(s)$ 定义为从状态 s 开始按某策略行事的期望累计回报，**动作值函数** $q(s,a)$ 定义为状态 s 采取动作 a 后按策略的期望回报。理解值函数满足的**贝尔曼等式**：当前价值等于即时奖励加未来价值的折现和 181 182。能写出最优值函数满足的贝尔曼最优方程 183。
- 学习**动态规划算法**在强化学习中的应用：掌握策略评估 (policy evaluation) 方法，通过贝尔曼期望方程的迭代来计算给定策略的值函数；掌握策略改进 (policy improvement) 原理，通过对当前值函数执行贪心选动作以提升策略 184 185。理解**策略迭代**(policy iteration) 的流程：策略评估和策略改进交替进行直至稳定 186 187。理解**价值迭代**(value iteration)：通过贝尔曼最优方程迭代逼近最优值函数，同时可推导最优策略。
- 能将动态规划应用于具体问题：以课程中的**网格世界 (Gridworld)** 为例，掌握状态表示（如4x4格子编号）、行动集合（上下左右移动）、奖励结构（如非终止步-1奖励等）的设定方法 188 189。学会通过编程实现网格世界的策略评估和优化，最终求得**最优策略**（例如找到从任意格子到目标的最短路径）。

- 了解异步动态规划和维度灾难概念：理解同步迭代更新值函数需要遍历整个状态空间，每次迭代成本随状态数增加线性增长，面对大型问题计算昂贵^{190 191}。知道异步DP通过不同时刻更新部分状态值，可加快收敛并缓解大规模计算压力，但需保证每个状态足够频繁地更新^{191 192}。体会在状态空间巨大（如金融连续状态模型离散化后）时DP方法的局限，为后续近似和强化学习方法做铺垫。

内容结构与核心概念

1. 强化学习与MDP背景：本模块首先回顾了强化学习(RL)的基本框架¹⁷⁹。金融背景下，可以将智能体视为一个交易策略或投资组合决策者，环境为市场。¹⁸⁰ 强化学习旨在让智能体通过与环境反复交互来学习最佳决策策略，例如学会在不同市场状态下买卖以最大化长期收益¹⁸⁰。马尔可夫决策过程(MDP)提供了RL问题的数学描述：在任何状态 s 执行动作 a ，都会有**即时奖励** $r(s,a)$ 并转移到下一个状态 s' ，且转移具有马尔可夫性质¹⁹³。在金融交易例子中，状态可定义为持有资产和价格水平，动作为买/卖/持有，奖励则是收益或损失。**折现因子** γ ($0 < \gamma < 1$)用于平衡近期奖励和远期奖励的重要性¹⁸¹。MDP的目标通常定义为最大化期望的累计折现总奖励 $E[\sum_{t=0}^{\infty} \gamma^t r_t]$ 。在强化学习中，**策略** π 是智能体的行动准则，定义为在各状态选择动作的概率分布或确定性规则¹⁷⁹。

2. 值函数与贝尔曼方程：值函数是RL中的核心概念，用于衡量策略的好坏¹⁷⁷。状态值函数 $v_{\pi}(s)$ 表示遵循策略 π 从状态 s 开始的长期累积回报期望；动作值函数 $q_{\pi}(s,a)$ 则进一步细化到执行特定动作 a 的价值。两者满足关系 $v_{\pi}(s) = \sum_a \pi(a|s) q_{\pi}(s,a)$ 。贝尔曼期望方程刻画了值函数的自治性质¹⁸¹：对于任意策略 π ，

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left[r(s, a) + \gamma \sum_{s' \in S} P(s'|s, a) v_{\pi}(s') \right],$$

即当前状态价值等于对各可能动作的加权（按策略概率）即时奖励加未来状态价值的折现和。这一定式可以视为一组线性方程，理论上可求解 v_{π} 。贝尔曼最优方程则描述了最优值函数 v_* 满足的关系¹⁸³：

$$v_*(s) = \max_{a \in A} \left[r(s, a) + \gamma \sum_{s'} P(s'|s, a) v_*(s') \right],$$

亦即在最优策略下，每个状态的价值等于选择使得“即时奖励+未来折现价值”最大的动作所得到的期望。如果能求解此非线性方程组，即可得到最优值函数和对应最优策略 π_* 。然而直接求解往往不可行，需要迭代算法逼近。

3. 策略评估 (Policy Evaluation)：在强化学习中通常采用迭代算法近似求解值函数。给定一个策略 π ，我们可以随机初始化一个值函数估计 $v(s)$ ，然后反复应用贝尔曼更新：

$$v_{new}(s) := \sum_a \pi(a|s) \left[r(s, a) + \gamma \sum_{s'} P(s'|s, a) v_{old}(s') \right].$$

这一更新将 v 推向贝尔曼方程的解。课程通过**网格世界**示例演示了策略评估¹⁹⁴。4×4的网格中，有固定终点和陷阱格子，每步移动奖励-1，其余为0，目标是达到终点最小化损失。若初始策略为随机走，策略评估可以算出各格子的价值近似等于负的步数距离（因为每走一步损失1）。课程Notebook实现了一个函数 `policy_evaluation(policy, tol)`，通过在整个状态空间上迭代更新直到值变动小于阈值 `tol` 停止^{186 194}。输出的 $v(s)$ 表明在该策略下从各格子出发的长期损失期望。

4. 策略改进与策略迭代：有了状态价值估计，就可以据此改进策略。**策略改进原理**（策略改进定理）说明：对任意非最优策略，如果有至少一个状态采用greedy（贪心）动作可以提高其价值，则更新该状态策略为贪心动作可改善整体策略绩效。实践中，实现策略改进的方法是：对于每个状态 s ，比较不同动作 a 的**Q值**

$$q_{\pi}(s, a) = r(s, a) + \gamma \sum_{s'} P(s'|s, a) v_{\pi}(s'),$$

选择使 q 最大的动作作为新策略 $\pi'(s)$ ¹⁸⁴。课程在网格世界中展示了这一过程：初始随机策略通过评估得到 $v(s)$ ，然后对于每个格子选出令 $v(s)$ 最大的方向（即朝向目标的方向），形成略优的策略。将新策略再做策略评估，再策略改进，如此循环即**策略迭代** ¹⁸⁶。通常，策略迭代能够在有限步内收敛到最优策略 π ，对应值函数 v 。在网格例子中，策略迭代最终得到一条从任意起点朝向终点的“箭头”路径，避开陷阱和死路，即为最优行动方案。课程笔记实现了策略迭代：使用前述 `policy_evaluation` 计算值函数，然后执行 `policy_improvement(value)` 生成新策略 ¹⁹⁵ ¹⁸⁵。反复进行直到策略不再改变 ¹⁹⁶ ¹⁹⁷。

5. 值迭代：值迭代是另一种等价求最优策略的方法，它直接对**贝尔曼最优方程**进行迭代：初始化 $v(s)=0$ ，随后不断更新

$$v(s) := \max_a \left[r(s, a) + \gamma \sum_{s'} P(s'|s, a) v(s') \right].$$

值迭代在每次迭代中都朝着最优值函数的方向调整，理论上收敛更快。课程提及**异步更新**的思想：与策略迭代中每轮需扫过所有状态不同，值迭代或异步DP可以选择随机顺序更新部分状态值（甚至可以优先更新“误差大”的状态），这被称为异步动态规划 ¹⁹¹。异步更新只要在无限循环中反复访问各状态足够多次，最终也会收敛到最优值。课程强调当状态空间非常大时（维度灾难），同时迭代所有状态代价高昂，因此异步或近似方法是必要的。**值迭代**配合异步更新可以视为一种更灵活的策略，在实践中经常使用。

6. 带随机性的环境：课程进一步探讨了如何处理环境随机性的DP方法。通过**有风的网格世界**（Windy Gridworld）案例说明：假设网格中存在向下的随机风，以概率 p_{down} 使智能体额外向下移动一格 ¹⁹⁸ ¹⁹⁹。这样状态转移变得随机，不再由动作唯一决定。然而DP框架依旧适用，只是在计算 Bellman 更新时向下移概率进行了加权。课程Notebook修改了策略评估函数，将转移部分拆成**风使然的下移**和**按策略行动**两部分 ²⁰⁰ ²⁰¹。结果显示，**最优策略发生了改变**：由于风的存在，智能体在上移时会有一定概率被吹回，最优策略会相应地在某些格子选择不同路径以减少风影响 ²⁰² ²⁰³。通过这个例子，学生了解到DP算法可以自然扩展到含随机干扰的情况，只需在状态转移概率中加入干扰因素即可。本质上，这重申了DP不需要环境确定性——它能处理转移概率，因此足以应付各种随机环境。

重要公式

- **状态值函数 (Value Function)** ¹⁸¹：给定策略 π ，状态值满足

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left[r(s, a) + \gamma \sum_{s' \in S} P(s'|s, a) v_{\pi}(s') \right],$$

这是贝尔曼期望方程，表示在策略 π 下状态 s 价值等于对每个可能动作的期望（即时奖励 + 折现后的后续状态价值）。

- **贝尔曼最优方程** ¹⁸³：

$$v_{*}(s) = \max_{a \in A} \left[r(s, a) + \gamma \sum_{s'} P(s'|s, a) v_{*}(s') \right].$$

任何最优策略对应的值函数满足上式。通过对比选择使括号内达到最大值的动作，即可得到最优策略 $\pi^{*}(s)$ 。

- **Bellman策略改进:** 动作值函数

$$q_{\pi}(s, a) = r(s, a) + \gamma \sum_{s'} P(s'|s, a) v_{\pi}(s')$$

表示在状态 s 执行动作 a 后遵循策略 π 的价值。若存在 $q_{\pi}(s, a') > v_{\pi}(s)$ ，则将策略在状态 s 改为选择 a' 能提高价值¹⁸⁴。策略迭代通过反复令 $\pi_{\text{new}}(s) = \operatorname{argmax}_a q_{\pi_{\text{old}}}(s, a)$ 来收敛到最优。

- **值迭代更新:**

$$v(s) \leftarrow \max_a \left[r(s, a) + \gamma \sum_{s'} P(s'|s, a) v(s') \right].$$

在值迭代算法中，以上更新重复执行直至 $v(s)$ 收敛¹⁹⁰。值迭代可看作策略评估与策略改进的合并：每次都直接选取当前值函数下的贪心动作更新值，因而通常比策略迭代更快。

- **异步动态规划:** 同步DP每次迭代用旧值函数计算所有状态的新值，再整体替换。而异步DP任意顺序更新状态，可用**就地更新**：

$$v(s) = \max_{a \in A} \left[r(s, a) + \gamma \sum_{s'} P(s'|s, a) v(s') \right]$$

即时写回 $v(s)$ ，然后选另一状态更新¹⁹¹。此方法节省内存且允许灵活安排更新顺序（例如更频繁更新变化大的状态）。

编程实现提示

本模块的Notebook通过**网格世界**这一可视化的例子详细演练了动态规划求解MDP的过程。首先，Notebook定义了**环境**：例如4x4网格，设定起点、终点和奖励函数。用二维数组或列表表示状态空间，用数值标识终点(奖励+0)和其他格子每步奖励-1等。然后定义**转移逻辑**：普通网格世界中，动作“上下左右”导致确定的下一个状态（若出界则停在原地）。Notebook可以通过预先建立一个 `destinations` 数组，大小 [状态数 × 动作数]，其中 `destinations[s, a]` 存储状态 s 执行动作 a 的下一个状态^{188 189}。对于边界格特殊处理（如试图上移出界则保持原位）^{189 204}。有了转移结构，后续计算就方便了。

策略评估的代码实现为一个函数 `policy_evaluation(policy, tol, gamma)`。其中 `policy` 可用一个数组表示，每个状态对应一个概率分布或确定动作。策略评估在代码中用**迭代更新**实现：可以采用同步更新（先计算一轮所有新值再赋值）或异步就地更新。Notebook中采取了同步方式：使用一个循环，每次创建新数组 `value_new` 来存放更新后的值，然后与旧值比较差异是否 $< \text{tol}$ 决定是否继续迭代^{187 194}。每次更新按贝尔曼期望式，对每个状态 s ，先取出策略指定的各可能动作及概率，然后用 NumPy 向量计算：

```
value_new[s] = sum( policy[s,a] * ( reward[s,a] + gamma * value_old[ dest[s,a] ] ) for a in actions )
```

这样即可得到新值。整个过程会输出或记录迭代次数，方便观察收敛速度。

策略改进在Notebook中实现为函数 `policy_improvement(value)` ¹⁹⁵ ¹⁸⁴。它遍历每个非终止状态 s ，计算各动作的 $Q(s,a)$ ，选取最大者。如果出现多个动作并列最大，代码中可能简单选择第一个（或随机选择之一）。最终构造出新的确定性策略数组。可以通过比较新旧策略发现变化位置，若无变化则策略稳定。

策略迭代综合上述两个函数：

```
policy = init_random_policy()
while True:
    value = policy_evaluation(policy)
    new_policy = policy_improvement(value)
    if new_policy == policy:
        break
    policy = new_policy
```

Notebook 的输出可以是每次策略迭代后的价值函数和策略（打印为箭头或方向），让学生看到策略如何逐步改善。

值迭代可实现为单一函数。代码通常以初始值函数为0向量开始，然后迭代：

```
while True:
    delta = 0
    for s in states:
        old_v = value[s]
        value[s] = max( reward[s,a] + gamma * value[ dest[s,a] ] for a in actions )
        delta = max(delta, abs(old_v - value[s]))
    if delta < tol: break
```

值迭代中同时也能记录greedy动作用于构造最终策略。Notebook在演示上可能更偏重策略迭代，因为概念分明，但值迭代实现让学生了解另一种思路。

有风的网格世界的实现则需要修改转移概率。Notebook增加一个参数 `p_wind` 表示向下风的概率 ¹⁹⁹。这样 `policy_evaluation` 要调整为：

$$v(s) = \sum_a \pi(s, a) \left[r(s, a) + \gamma (p_{down} v(\text{downDest}) + (1 - p_{down}) v(\text{dest}(s, a))) \right].$$

代码可以体现在计算 `value_new[s]` 时，如果动作有效导致状态 s' ，还要加上一项风导致下移的状态 s_{down} (可能从 s 或 s' 向下)的价值乘以 `p_wind`。 ²⁰⁰ ²⁰¹。Notebook通过这种修改计算带风情形下的价值函数，再进行策略改进。由于环境变随机，最优策略可能改变：在受风影响严重的列上，策略可能倾向于先横移再纵移，或者在有风区下方绕行等。Notebook可以打印或可视化有风时最优策略，让学生对比无风策略的差异。例如，在风概率 $p=0.1$ 的例子中，可以观察智能体开始会稍微偏向下方的路径，以利用风推力或避免逆风。 ²⁰² 课程鼓励学生试验不同 p 值或风向，Notebook也提供了接口调整 `p_wind` 并重新运行DP计算，从而体会探索-利用之外，**MDP建模对策略结果的影响**。

课程练习与回顾建议

- **手工推演网格世界DP**: 建议学生对一个小型网格（例如2x2或3x3，没有风）尝试手工推导最优值函数和策略。可以列出每个格子的贝尔曼方程，通过迭代求解。此练习帮助巩固贝尔曼方程直观意义，并检查对DP计算的理解。
- **编程实验不同奖励设置**: 修改网格世界的奖励结构，例如增加在特定危险格子的高负奖励，或在沿途设置小正奖励。然后运行策略迭代，看最优路径如何改变。通过这种实验，学生可以体会MDP模型对策略的敏感性和鲁棒性。
- **异步更新效果比较**: 让学生将 Notebook 中策略评估或值迭代的同步更新改为异步更新（就地更新每个状态）。测试在同样阈值tol下，两种更新策略的迭代次数差异。如果异步更新更快收敛，可以引导学生思考原因（因为异步利用新值即时传播）。
- **“维度灾难”体验**: 构造一个较大状态空间的DP问题（比如8x8网格），对比计算时间。学生会发现状态数翻倍，策略评估迭代可能明显变慢。由此直观感受DP方法扩展到高维的困难。这为后续模块引入近似方法（如蒙特卡洛、TD学习）埋下伏笔。
- **阅读与拓展**: 深入阅读 Sutton 和 Barto 《Reinforcement Learning》关于动态规划的章节，以获得更加系统和严格的解释。尝试将文中的示例（如**赌博机问题**）用代码实现DP求解。这不仅复习了本模块内容，也为下一模块理解蒙特卡洛和时序差分方法打好基础。

模块 6：强化学习策略与多臂老虎机问题 (Multi-armed Bandits in RL)

学习目标

- **理解探索 vs. 利用 (Exploration-Exploitation) 冲突**: 认识到在未知环境中学习策略时，智能体需要在尝试新动作获取信息（探索）和利用当前已知最优动作获取奖励（利用）之间权衡 205 206。了解盲目利用可能陷入次优方案，而过度探索会降低短期收益。
- **掌握典型的多臂老虎机模型**: 将探索-利用问题形式化为k-臂老虎机(k-armed bandit)实验，每个臂（动作）有未知的奖励分布，智能体每轮选择一个拉杆获得收益 207 208。理解该模型反映了诸如投资多个资产、选择交易策略等场景中需要试错学习的问题。
- **学习常用的探索策略**: 包括
 - **ϵ -贪心策略**: 以概率 ϵ 随机探索、概率 $1-\epsilon$ 选择当前估计最好臂 209 210。理解 ϵ 控制探索程度， ϵ 较大则会更多尝试未知选项， ϵ 较小则更偏重利用。
 - **乐观初始值**: 通过将初始估计奖励设定较高值来鼓励早期探索 206 210。直观上，因所有臂最初看起来都很“好”，智能体会逐一尝试，直到收敛到真实水平。
 - **上置信界 (UCB) 算法**: 根据奖励置信区间选臂，每次选择 $a = \arg \max [\bar{Q}(a) + c\sqrt{\frac{\ln t}{N_t(a)}}]$ 211。理解UCB中第二项为“乐观值”，随臂尝试次数 $N_t(a)$ 增加而减小，使较少尝试的臂获得额外“加分”以被探索 211 212。c 参数控制探索力度。
 - **Softmax/概率匹配**: 按指数形式将估计价值转化为选择概率（如 Boltzmann 分布），即 $P(a) = \frac{\exp(Q(a)/\tau)}{\sum_b \exp(Q(b)/\tau)}$ 213。了解温度参数 τ 调节探索随机性， τ 高时近乎均匀探索， τ 低时趋近贪心利用。
- **了解奖励估计更新方法**: 如简单平均法 $Q_{n+1} = Q_n + \frac{1}{N_{n+1}}(R_{n+1} - Q_n)$ 实时更新每臂平均奖励 214 215，以及**增量式更新公式**避免存储全部历史。理解步长参数 α 可以用于加权最近奖励更多（非恒定环境）。
- **将多臂老虎机理论应用于股票投资案例**: 理解如何将选股问题建模为多臂老虎机：臂=备选股票，每日一次决策选哪只股票买入持有一天，奖励=次日收益 207 208。认识股票收益分布会随时间变化（非平稳），需要算法能够跟踪变化（比如逐步减少探索或使用滑动窗口平均）。通过案例学习评估不同策略在金融序列数据上的表现，如累计收益、选择频率、后悔值等指标。

内容结构与核心概念

1. 探索-利用困境概述: 在强化学习中，智能体既要利用已有知识获得高奖励，又要探索未知以获取更好长期回报 216。课程以**多臂老虎机问题**为切入，这是一类纯粹探索-利用问题，没有复杂状态转移。假设有 k 台老虎

机，每台赔率/期望奖励不同且未知，玩家每次选择一台拉杆赢取奖励，希望通过试验逐步找到回报最高的老虎机²⁰⁷。这个问题揭示了探索的重要性：如果玩家只反复拉最开始收益高的机器，可能错失另一台更优机器的机会。反之，一味平均尝试则浪费机会成本。课程指出，在老虎机问题中，度量学习算法好坏的指标之一是“累积懊悔”(Cumulative Regret)：即与始终拉最优臂相比少获得的总奖励。一个优秀的策略应使懊悔随时间增长尽可能慢（理想情况下对数增长）。

2. ϵ -贪心策略：课程首先介绍最简单的探索策略—— ϵ -贪心²⁰⁶。算法很直观：以极小概率 ϵ 随机选任意一臂探索，以大概率 $1-\epsilon$ 选择当前平均奖励最高的臂²⁰⁶。 ϵ 相当于探索率，可以随时间调度（如逐渐减小）。优点是实现简单，容易取得比纯贪心更好的长期表现；缺点是在真实最优臂已经被准确识别后仍浪费 ϵ 的时间去探索次优臂。课程通过公式推导 ϵ -贪心的懊悔上限为线性增长，不过如果逐步衰减 ϵ ，理论上懊悔可做到对数级。直观感受： ϵ -贪心确保所有臂都会被偶尔试一试，不至于永远放弃潜在好的臂。

3. 乐观初始值：另一种增加探索的方法是不改变策略结构，而是初始化时将所有臂的估计 Q 值设置为一个比现实更高的值²¹⁰。这样算法最初会倾向于每个臂至少试一次，因为都看起来有高收益潜力。随着观察到实际奖励低于初始预期，估计值才下降；未尝试的臂保持高预期值持续吸引探索。这是一种“内置”探索激励策略，无需随机性。课程指出，乐观初始值对静态问题表现良好，但在非平稳环境中不适用，因为初始偏置无法解决随时间的变化。

4. UCB算法：上置信界策略充分利用了概率统计知识：对每个臂构造“置信上界”来平衡贪心和探索²¹¹。具体公式：

$$a_t = \arg \max_a \left[\bar{Q}_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right],$$

其中 $\bar{Q}_t(a)$ 是到目前为止臂 a 的平均奖励，后项 $\sqrt{\frac{\ln t}{N_t(a)}}$ 则是置信区间宽度²¹¹。直观理解：若某臂尝试次数 N 很少，则第二项很大，即使当前均值不高，总和仍可能超过其他臂鼓励被选；随着 N 增加，这个额外奖励会减小。当所有臂都被充分尝试后，UCB自然会收敛为贪心选择当前均值最高者。参数 c 决定置信区间的宽度（通常 c =适当的概率分布常数，如1、2等）。课程强调，UCB有较好的理论性能：懊悔期望可做到对数级增长，因为它能保证每臂尝试次数 $N_t(a)$ 约为 $O(\ln t)$ ，既不过少也不浪费²¹¹。UCB策略体现了一种“乐观则治”：假设不确定的臂潜在收益可能很高，从而进行探索验证。

5. Softmax (Boltzmann) 策略：相比 ϵ -贪心的“要么随机要么贪心”，Softmax提供了一种平滑随机策略²¹³。它根据各臂估计价值的指数，将它们转化为选择概率：

$$P(a) = \frac{\exp(Q(a)/\tau)}{\sum_b \exp(Q(b)/\tau)}.$$

这里温度参数 τ 控制随机性： $\tau \rightarrow 0$ ，使最大的 Q 值臂概率趋近1（接近贪心）， τ 很大则各臂概率接近平均（近乎纯探索）²¹³。Softmax策略保证所有臂都有非零概率被选，但高估值臂有指数级更高的概率，从而实现“按价值加权的探索”。这种概率匹配策略在实践中可减少因 ϵ -贪心可能忽略价值差异的缺点。例如，对于两个臂估计值相差悬殊的情况， ϵ -贪心还是会 ϵ 概率选劣臂，而Softmax会几乎只选好的臂，除非它们价值接近。课程可能介绍渐近最优策略（如Gittins指数用于有折现的情形）但考虑篇幅主要聚焦上述常用启发式方法。

6. 奖励估计的更新：多臂老虎机中的关键之一是如何更新对每个臂的价值估计 $Q(a)$ 。课程介绍了增量平均法：每次选择臂 a 获得奖励 R ，利用公式

$$Q_{new}(a) = Q_{old}(a) + \alpha[R - Q_{old}(a)]$$

进行更新²¹⁴。当选择固定步长 $\alpha = 1/(N(a) + 1)$ 时，上式正是求奖励的累积平均²¹⁴。该方法无需存储历史，只保留当前均值和计数 N ，即可迭代更新。对于**非平稳**环境，课程建议使用**常数步长** α （如0.1），这样历史较早的奖励影响会逐渐衰减，算法能更快适应分布变化。比如在股市场场景中，近期行情变化会导致过去的最优臂不再最佳，用常数步长能够更及时地调整 Q 值。

7. 股票多臂老虎机案例：课程将上述概念应用于金融，构造了一个**股价动量策略**的多臂老虎机实验²⁰⁷。假设有5只股票（AAPL, AMZN, MSFT, NVDA, TWTR）可供每日选择持有一天。每一天结束后得到所选股票一天的价格涨幅作为奖励²¹⁷。这个问题的特殊之处在于：股票收益分布**非平稳**，因为市场环境和公司基本面在变。课程鼓励使用逐步减小探索率或常数步长来应对。Notebook 实现了这一实验：首先读取历史价格数据^{218 175}，计算每日收益序列。然后实现一个选股算法，如 ϵ -贪心 或 UCB，并仿真每天投入选择。代码中定义 `optimal_action(q_values, eps)` 函数，根据当前 Q 估计和 ϵ 输出选择的股票索引^{219 220}；定义 `reward_update(action, reward, qvalue_old, alpha)` 更新所选股的价值估计²²¹。主循环遍历每个交易日，在每天开盘前根据策略选股，在收盘后观察当日收益作为 `reward` 更新估计^{175 176}。为评估效果，Notebook 计算累计盈利曲线，或者计算模型选择的股与实际最优股收益差距(懊悔)。课程发现，在这个真实案例中，固定策略很难永远跑赢市场，但一个合理的探索策略至少能逐渐**识别出平均收益较高的股票**（如科技股 NVDA在某段时期上涨更多，则算法会越来越多地选择它）。当市场风格转变（如一段时间后另一股票开始领涨），算法如果步长设置得当，也能通过不断探索跟上变化。Notebook 可能绘制出每只股票被选次数随时间的分布，以及累计资产曲线，与被动平均持有或总选最强股两种对比，以展示算法的性能。课程强调，**多臂老虎机策略是强化学习在无状态情形下的基础**，后续更复杂的 RL 算法（如 Q-learning）在本质上也要处理探索-利用，只是扩展到有状态的情况。

重要公式

• ϵ -贪心策略：

$$\pi(a|s) = \begin{cases} 1 - \epsilon + \epsilon/|A|, & \text{if } a = \arg \max_{a'} Q(s, a'), \\ \epsilon/|A|, & \text{otherwise.} \end{cases}$$

对多臂老虎机而言没有状态 s ，上式简化为在每轮以概率 ϵ 随机选任一臂，否则选择当前估计奖励最高的臂。 ϵ 可固定或随时间衰减。

• UCB 动作选择²¹¹：

$$a_t = \arg \max_a \left[\bar{Q}_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right],$$

其中 $\bar{Q}_t(a)$ 是臂 a 在第 t 轮前的平均奖励， $N_t(a)$ 是第 t 轮之前臂 a 被拉的次数²¹¹。每轮都选择上置信界估计最高的臂。 c 通常取经验值如 1 或 2 控制探索程度。UCB 策略理论上对静态分布达到对数级懊悔。

• Softmax (Boltzmann) 策略²¹³：

$$P_t(a) = \frac{\exp(Q_t(a)/\tau)}{\sum_b \exp(Q_t(b)/\tau)},$$

智能体按上述概率分布随机选择动作。 τ 是温度参数, $\tau \rightarrow 0$ 时趋于贪心选择, $\tau \rightarrow \infty$ 时近乎均匀随机。Softmax在兼顾探索的同时, 更倾向于选择高估值动作。

- **增量式奖励平均** ²¹⁴: 对每次选择的臂 a , 奖励 R , 更新估计值

$$Q_{\text{new}}(a) = Q_{\text{old}}(a) + \alpha [R - Q_{\text{old}}(a)],$$

当 $\alpha = \frac{1}{N(a)+1}$ 时, 此更新等价于计算新的算术平均 ²¹⁴。在非平稳环境中, 可选较大的常数步长 (如 0.1) 使最近奖励权重更高。

- **Stock-picking Bandit**: 每日选择一支股票 i 并观察收益 $R_i(t)$ 。策略目标是最大化长期累积收益 $G_T = \sum_{t=1}^T R_{\text{chosen}(t)}(t)$ 。懊悔定义为 $\text{Regret}(T) = \sum_{t=1}^T [R_{a^*(t)}(t) - R_{\text{chosen}(t)}(t)]$, 其中 $a^*(t)$ 是当日最佳股票。一个好的算法应让 Regret 随 T 次序增长缓慢 (尽量小)。

编程实现提示

在本模块的Notebook中, 学生将实现多种探索策略并在模拟和真实数据上测试。首先, 可定义一个通用框架: 比如类 `BanditAgent`, 包含属性如 `Q` 值数组、选择计数数组 `N`, 方法如 `select_action()` 和 `update_estimation(action, reward)`。这样不同策略可以通过继承该类并重写 `select_action` 实现具体逻辑。

ϵ -贪心: 代码里 `select_action` 可以如下实现 ²¹⁹:

```
if np.random.rand() < epsilon:
    return np.random.randint(0, k) # 随机探索
else:
    return np.argmax(Q_values)     # 贪心利用
```

简单明了。

乐观初始值: 在初始化 `Q_values` 时将所有值设为一个高数, 比如可以设为奖励上限值。这无需改变选择函数。学生可以观察到, 初期代理会把每个臂都试一遍, 因为刚开始每个臂都有同样高的估计, 首次尝试会揭示真实较低的奖励并降低估计值。

UCB: 需要跟踪每个臂的 `N` 值。`select_action` 实现可以先为还未尝试的臂返回一个 (以确保每臂至少被选一次), 否则计算上述公式 ²¹¹:

```
ucb_values = Q_values + c * np.sqrt(np.log(total_count) / N_values)
return np.argmax(ucb_values)
```

代码需注意处理除零, 通常可对未选过的臂赋一个很大的 UCB 值先试之。

Softmax: `select_action` 里先计算 `exp_Q = np.exp(Q_values / tau)`, 归一化为概率, 然后用 `np.random.choice(k, p=prob)` 按这些概率抽样动作 ²¹³。这比 ϵ -贪心多了一步概率抽样, 但Python实现也较直接。

奖励更新：课程采用增量平均公式实现，因此 `update_estimation` 方法可写：

```
N[action] += 1
Q[action] += (reward - Q[action]) / N[action]
```

若用常数步长 α ，则可写 `Q[action] += alpha * (reward - Q[action])`。

在**模拟试验**中，课程可能先用Python合成一个固定收益率分布的老虎机环境测试各策略懊悔曲线。比如定义一个数组 `true_means = [0.1, 0.5, 0.2]` 表示每臂平均胜率，然后运行 agent 选择1万次，记录累计奖励。可以绘制每种算法的平均懊悔或总奖励随轮次增长图，从而验证UCB懊悔对数增长优于 ϵ -贪心线性增长等理论预期。

股票数据试验：Notebook 读取股票历史价 ¹⁷⁵ 生成价格序列矩阵，计算每日收益。如果数据长度N天、k只股票，则构造每日收益矩阵 `returns[day, stock] = (Price[day+1, stock] - Price[day, stock]) / Price[day, stock]`。然后初始化BanditAgent，循环天 `t=0` 到 `N-2`：每轮用 `action = agent.select_action()` 得到股票索引，获得对应的 `reward = returns[t, action]`（或 `t->t+1` 这段收益），调用 `agent.update_estimation(action, reward)` 更新。可以跟踪 agent 每种股票被选择次数 `N`，最终看看是否更多选择了平均收益最高的股票。

结果评估：Notebook 可能绘制累计资产价值曲线：假设初始资金1，之后每轮根据选股收益乘以 $(1 + \text{reward})$ 。将这些值画出来，与若每次都买收益最高那只股（先知策略）以及平均分散持有的基准比较。若算法足够好，其曲线应逐渐接近先知策略并明显好于均分基准。

另一个分析是绘制**每支股票被选频率**随时间变化，例如每100天统计一次各股票选择比例。一个理想的算法在足够长时间后应该主要选中真正长期回报最高的股票，而对其他股票只偶尔探索。

通过这些可视化，学生可以看到例如： ϵ -贪心在静态或缓慢变动市场表现尚可，但在剧烈变化（板块轮动快）下就需要设置衰减的 ϵ 或常数步长；UCB在静态情况下收益高但在非平稳情况下可能反应略慢等现象。这为后续进阶的时序差分学习和策略函数近似做好铺垫。

课程练习与回顾建议

- **参数敏感性实验：**建议学生针对每种策略，尝试不同参数设置并观察表现差异。例如：改变 ϵ 大小（0.1, 0.01等）看贪心程度对累计奖励的影响；改变 UCB 中 c （0.5, 2等）看探索强度变化；改变 Softmax 温度 τ 。通过实验，学生会发现合适的探索参数需要根据问题特性调节，如非平稳环境需更高探索等。
- **非平稳环境测试：**设计一个模拟实验：臂的真实平均奖励在某时刻发生改变（比如50轮后交换两个臂的均值）。让不同策略在此环境运行比较。当变化发生后，哪个策略能更快识别新的最优臂？学生可通过观察调整步长或 ϵ 衰减策略来改进算法适应性。
- **多臂老虎机理论验证：**选取一些简单情形验证理论结果，如2臂伯努利奖励分布，用公式计算最优解和懊悔，再通过多次模拟估计算法懊悔，验证UCB懊悔增长近似 $\log(t)$ 。虽然需要一定统计，但这个练习可以加深对策略性能的定量理解。
- **金融数据扩展：**学生可以尝试将选股问题拓展：增加更多股票，或者使用不同市场时期的数据（牛市vs熊市）。观察强化学习策略在不同市场条件下表现如何。例如，在单边上涨市场，贪心策略很快锁定领涨股即可，但在震荡市可能需要持续探索。通过这些练习，学生体会RL策略在实际金融中的适用场景和局限。
- **预习强化学习进阶：**鼓励学生思考：多臂老虎机没有状态，如果加入状态（如根据一些市场指标调整策略），探索-利用问题会更复杂，简单的 ϵ -贪心如何扩展？这些问题为下一步学习**时序差分学习和函数逼近**埋下思考伏笔，让学生意识到探索策略与值函数近似的结合是更高阶挑战。

1 2 4 5 6 7 8 9 11 12 13 14 15 16 22 39 40 Google Drive

https://drive.google.com/file/d/1aZrOmlD_coAWWGcNFXTDzZlaBemrjpUl

3 10 Google Drive

https://drive.google.com/file/d/1Tmck_vmdUo2mPD3zxaBccSX6NkpWYY10

17 18 19 20 21 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 Google Drive

<https://drive.google.com/file/d/1htxmQ-FKwVfEDB4gD5OckjkAvHIAAumi>

41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 73 74 87 Google Drive

https://drive.google.com/file/d/1Dsg_10uJLjvGfZRMvKMAv8KzRKLWl7H

56 64 65 82 83 94 95 107 108 109 110 111 112 Google Drive

<https://drive.google.com/file/d/1PK6IWk5BEN8Ruptg7dl1HYyuGoZoX8gl>

57 58 59 66 67 68 69 70 75 76 77 78 79 80 81 Google Drive

<https://drive.google.com/file/d/11s13MpAaLmyqnXTeS8mXRohkSHLGyxoU>

60 61 62 63 Google Drive

<https://drive.google.com/file/d/18xw4oH5LUqr3wNI8E3e0QNI-UEg2pZM7>

71 72 84 85 86 92 93 96 101 102 103 104 105 106 113 114 115 116 117 123 124 125 126 127 Google Drive

<https://drive.google.com/file/d/15pwJi3dXSizuw-nOXUzb7eKAwRLxa9UT>

88 89 90 91 97 98 99 100 118 119 120 121 122 Google Drive

<https://drive.google.com/file/d/1BkCBGlb8eq33EcWmwJaF9r5kW-41JsEy>

128 129 130 144 145 146 168 Google Drive

<https://drive.google.com/file/d/1uDp-HGuQ2XUBjz2kytSspy6xEXTeeCN0>

131 132 133 134 147 148 149 150 151 169 170 171 Google Drive

<https://drive.google.com/file/d/128JMS4Cy6is8WfvQkF2pgy8QhC3MKbEs>

135 136 137 152 153 154 166 167 172 173 174 Google Drive

https://drive.google.com/file/d/1Bk_ltn2eMaVKYybXIWNKEM1TeNwJHAI

138 139 140 141 142 143 155 156 157 158 159 160 161 162 163 164 165 Google Drive

<https://drive.google.com/file/d/1fjLkUJAttaZ6KsF-prVGyhNc220YTKbs>

175 176 206 207 208 209 210 211 212 213 214 215 216 217 218 219 220 221 Google Drive

https://drive.google.com/file/d/13nmUwr77-_ixHGge2jYOIVHoMwXQb3lV

177 178 179 180 181 182 183 193 205 Google Drive

<https://drive.google.com/file/d/1s78vJexO8beG79j0Ctj4wOc8T8dEJ1TN>

184 185 186 187 188 189 190 191 192 194 195 196 197 198 199 200 201 202 203 204 Google Drive

<https://drive.google.com/file/d/1XRvriSM9wRI2oX0jF3lrlwPmJwbXn64E>